

Simulaciones y comparación. Sesgo teórico - Sesgo simulado



UNIVERSIDAD
NACIONAL
DE COLOMBIA

Anàlisis de regresión

Ana Lucia Acosta Moreno

Camilo Andres Murcia Perdomo

David Camero Pardo

Sergio Alejandro Buitrago Melo

22/SEP/2026

Tarea regresión

Ana Lucía Acosta Moreno

Sergio Buitrago Melo

David Camero Pardo

Camilo Andrés Murcia Perdomo

Datos y modelo base de la estimación

Se usan los datos y el modelo que se han venido trabajando durante la clase: las variables precio y km de la base de datos “mazda2021”.

```
#Datos
mazda<-readxl::read_xlsx(path = "mazda2021.xlsx") #adaptar ruta en caso de ser necesario

#Modelo y varianza poblacional
model<- lm(data= mazda, precio ~ km)
summary(model)
```

Call:

```
lm(formula = precio ~ km, data = mazda)
```

Residuals:

Min	1Q	Median	3Q	Max
-26067817	-8885238	-654205	8740388	50928133

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	6.972e+07	1.027e+06	67.90	<2e-16 ***
km	-2.205e+02	9.681e+00	-22.78	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 11840000 on 530 degrees of freedom

Multiple R-squared: 0.4948, Adjusted R-squared: 0.4938

F-statistic: 519 on 1 and 530 DF, p-value: < 2.2e-16

```
#varianza poblacional
sigmasqrd_est<-sum(model$residuals^2)/(length(model$residuals))
```

De igual manera, iniciamos objetos que serán necesarios a lo largo de la simulación.

```
diffs <- numeric(1000) #Diferencias entre varianza sesgada y varianza insesgada
var_sesgada <- numeric(1000)
sigma2_insesgada <- numeric(1000)
```

Calculamos la varianza real del modelo (se usará para el cálculo del sesgo teórico).

```
# Varianza true
sigma2_true <- sum(model$residuals^2) / (length(model$residuals) - 2)
```

Generación de las 1000 simulaciones y cálculo del “sesgo simulado”

Usando un `for` se repite mil veces un bucle que llena el *i*-ésimo dato de los tres objetos definidos anteriormente (`diffs`, `var_sesgada`, `sigma2_insesgada`). Cada iteración toma una muestra y guarda las varianzas en esos objetos.

```
for (i in 1:1000) {
  set.seed(i)
  idx <- sample(seq_len(nrow(mazda)), size = 100, replace = FALSE)
  muestra <- mazda[idx, c("precio", "km")]

  modelo_sim <- lm(precio ~ km, data = muestra)

  # Estimador sesgado:
  var_sesgada[i] <- sum(residuals(modelo_sim)^2) / 100

  # Varianza de la muestra insesgada
  sigma2_insesgada[i] <- sum(modelo_sim$residuals^2) / (length(modelo_sim$residuals) - 2)

  # Guardar la diferencia entre estimador sesgado y true
  diffs[i] <- var_sesgada[i] - sigma2_insesgada[i]
}
```

Cálculo de la fórmula del sesgo teórico:

Partimos del estimador insesgado de la varianza de los errores:

$$\hat{\sigma}_{insesgado}^2 = \frac{RSS}{n-p}$$

Por lo tanto, el valor esperado de RSS es

$$E[RSS] = (n-p)\sigma^2$$

Ahora, nuestro estimador sesgado es:

$$\hat{\sigma}_{sesgado}^2 = \frac{RSS}{n}$$

con valor esperado de:

$$E[\hat{\sigma}_{sesgado}^2] = E\left[\frac{RSS}{n}\right] = \frac{n-p}{n}\sigma^2$$

Es decir, podemos ver el sesgo como:

$$\text{Sesgo} = E[\hat{\theta}] - \theta$$

Esto, en nuestro caso, sería:

$$\text{Sesgo} = \frac{n-p}{n}\sigma^2 - \sigma^2 = \sigma^2 \left(\frac{n-p}{n} - 1 \right) = \sigma^2 \left(\frac{-p}{n} \right) = -\frac{p}{n}\sigma^2$$

Con $p = 2$:

$$-\frac{2}{100}\sigma^2$$

Siendo este nuestro sesgo teórico a comparar.

Comparación del sesgo simulado VS sesgo teórico

Debido al tamaño de los números tomados en estas simulaciones (la varianza se encuentra en millones de pesos cuadrados), se compararán los sesgos como un cociente, no como la diferencia, con el objetivo de dar una interpretación más clara.

Preparamos el sesgo teórico y el promedio de nuestras simulaciones.

```
#sesgo promedio de las simulaciones
sesgo_prom <- mean(diffs)

# Sesgo teorico para comparación
sesgo_teorico <- - (2 / 100) * sigma2_true #como fue calculado anteriormente
head(diffs)
```

```
[1] -3.280249e+12 -2.702168e+12 -2.187121e+12 -2.800739e+12 -2.299850e+12
[6] -2.709330e+12
```

```
c(sesgo= sesgo_prom , "sesgo teorico"= sesgo_teorico)
```

```
      sesgo sesgo teorico
-2.801038e+12 -2.801776e+12
```

Realizando el cociente obtenemos:

```
sesgo_prom / sesgo_teorico
```

```
[1] 0.9997367
```

La salida indica un cociente de 0.9997367.

Conclusiones

Dado que al realizar el cociente obtuvimos un valor muy cercano a 1, se puede concluir que la diferencia entre el sesgo simulado y el sesgo teórico es atribuible a la aleatoriedad de la muestra que se tomó.