

Tarea regresión

En esta simulacion se usará la base de datos “mazda2021” para realizar una simulacion práctica de los estimadores de varianza vistos en clase y ver de manera orgánica el sesgo del estimador de mayor verosímilitud.

A continuación se explica el proceso computacional y matemático del calculo de los sesgos “simulados” y “teóricos” a partir de los estimadores de varianza.

Datos y modelo base de la estimación

Se usan los datos y el modelo que se han venido trabajando durante la clase: las variables precio y km de la base de datos “mazda2021”.

```
#Datos
#adaptar ruta en caso de ser necesario
mazda<-readxl::read_xlsx(path = "mazda2021.xlsx")

#Modelo y varianza poblacional
model<- lm(data= mazda, precio ~ km)
summary(model)
```

Call:

```
lm(formula = precio ~ km, data = mazda)
```

Residuals:

Min	1Q	Median	3Q	Max
-26067817	-8885238	-654205	8740388	50928133

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	6.972e+07	1.027e+06	67.90	<2e-16 ***
km	-2.205e+02	9.681e+00	-22.78	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 11840000 on 530 degrees of freedom

Multiple R-squared: 0.4948, Adjusted R-squared: 0.4938

F-statistic: 519 on 1 and 530 DF, p-value: < 2.2e-16

```
#varianza poblacional
sigmaqr_est<-sum(model$residuals^2)/(length(model$residuals))
```

De igual manera, iniciamos objetos que serán necesarios a lo largo de la simulación.

```
#Diferencias entre varianza sesgada y varianza insesgada
diffs <- numeric(1000)
var_sesgada <- numeric(1000)
sigma2_insesgada <- numeric(1000)
```

Calculamos la varianza real del modelo (se usará para el cálculo del sesgo teórico).

```
# Varianza true
sigma2_true <- sum(model$residuals^2) / (length(model$residuals) - 2)
```

Generación de las 1000 simulaciones y cálculo del “sesgo simulado”

Usando un `for` se repite mil veces un bucle que llena el *i*-ésimo dato de los tres objetos definidos anteriormente (`diffs`, `var_sesgada`, `sigma2_insesgada`). Cada iteración toma una muestra y guarda las varianzas en esos objetos.

```
for (i in 1:1000) {
  set.seed(i)
  idx <- sample(seq_len(nrow(mazda)), size = 100, replace = FALSE)
  muestra <- mazda[idx, c("precio", "km")]

  modelo_sim <- lm(precio ~ km, data = muestra)

  # Estimador sesgado:
  var_sesgada[i] <- sum(residuals(modelo_sim)^2) / 100

  # Varianza de la muestra insesgada
  sigma2_insesgada[i] <- sum(modelo_sim$residuals^2) / 100 - 2

  # Guardar la diferencia entre estimador sesgado y true
  diffs[i] <- var_sesgada[i] - sigma2_insesgada[i]
}
```

Cálculo de la fórmula del sesgo teórico:

Partimos del estimador insesgado de la varianza de los errores:

$$\hat{\sigma}_{insesgado}^2 = \frac{RSS}{n-p}$$

Por lo tanto, el valor esperado de RSS es

$$E[RSS] = (n-p)\sigma^2$$

Ahora, nuestro estimador sesgado es:

$$\hat{\sigma}_{sesgado}^2 = \frac{RSS}{n}$$

con valor esperado de:

$$E[\hat{\sigma}_{sesgado}^2] = E\left[\frac{RSS}{n}\right] = \frac{n-p}{n}\sigma^2$$

Es decir, podemos ver el sesgo como:

$$\text{Sesgo} = E[\hat{\theta}] - \theta$$

Esto, en nuestro caso, sería:

$$\text{Sesgo} = \frac{n-p}{n}\sigma^2 - \sigma^2 = \sigma^2 \left(\frac{n-p}{n} - 1 \right) = \sigma^2 \left(\frac{-p}{n} \right) = -\frac{p}{n}\sigma^2$$

Con $p = 2$:

$$-\frac{2}{100}\sigma^2$$

Siendo este nuestro sesgo teórico a comparar.

Comparación del sesgo simulado VS sesgo teórico

Debido al tamaño de los números tomados en estas simulaciones (la varianza se encuentra en millones de pesos cuadrados), se compararán los sesgos como un cociente, no como la diferencia, con el objetivo de dar una interpretación más clara.

Preparamos el sesgo teórico y el promedio de nuestras simulaciones.

```
#sesgo promedio de las simulaciones
sesgo_prom <- mean(diffs)

# Sesgo teorico para comparación
sesgo_teorico <- - (2 / 100) * sigma2_true #como fue calculado anteriormente
head(diffs)
```

```
[1] 2 2 2 2 2 2
```

```
c(sesgo= sesgo_prom , "sesgo teorico"= sesgo_teorico)
```

```
      sesgo sesgo teorico
2.000000e+00 -2.801776e+12
```

Realizando el cociente obtenemos:

```
sesgo_prom / sesgo_teorico
```

```
[1] -7.13833e-13
```

La salida indica un cociente de 0.9997367.

Conclusiones

Durante el proceso de comparacion se decidió el cambio de comparar los sesgos mostrando la diferencia a mostrar el cociente puesto que a pesar de que, a escala, la diferencia entre nuestros sesgos es bastante baja; entendimos que al tratarse de unidades tan grandes seria pertinente pivotar hacia el uso del cociente como metodo de comparacion de manera mas interpretable.

Dado que al realizar el cociente obtuvimos un valor muy cercano a 1, se puede concluir que la diferencia entre el sesgo simulado y el sesgo teórico es atribuible a la aleatoriedad de la muestra que se tomó. Esto confirma de manera práctica el sesgo de nuestros estimadores vistos en clase. Así indicando una buena implementacion de un estimador insesgado como alternativa estadísticamente mas viable.